BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT TP. HCM

KHOA CÔNG NGHỆ THÔNG TIN

□□&□□

HCMUTE

TIỂU LUẬN KẾT THÚC HỌC PHẦN

HỌC KỲ II/2025-2026

TOÁN CHO TRÍ TUỆ NHÂN TẠO

ỨNG DỤNG SVD BẢO TOÀN KHÔNG GIAN ĐẶC TRƯNG KHI TÁI HUẤN LUYỆN MÔ HÌNH CHO BÀI TOÁN PHÂN LOẠI ẢNH GIẢ KHUÔN MẶT

GVHD: GV.TS. Bùi Mạnh Quân

MÃ HP: MAAI330985_01CLC

NHÓM SINH VIÊN THỰC HIỆN:

STT	HỌ VÀ TÊN	MSSV
1	Phùng Lê Thanh Quân	23110145
2	Nguyễn Đức Thịnh	23110156

Tp. Hồ Chí Minh, tháng 3 năm 2026

DANH SÁCH CÁC THÀNH VIÊN THAM GIA TIỂU LUẬN

HỌC KÌ II NĂM HỌC 2025 – 2026

Chủ đề: Ứng dụng phân rã giá trị kỳ dị (SVD) bảo toàn không gian đặc trưng khi tái huấn luyện mô hình kết hợp cho bài toán phân loại ảnh giả khuôn mặt

STT	HỌ TÊN SINH VIÊN	MSSV	KẾT QUẢ
1	Phùng Lê Thanh Quân	23110145	Hoàn thành 100%
2	Nguyễn Đức Thịnh	23110156	Hoàn thành 100%

Ghi chú: - Tỉ lệ % = 100%

- Trưởng nhóm: Phùng Lê Thanh Quân

ĐÁNH GIÁ, NHẬN XÉT CỦA GIẢNG VIÊN CHẤM ĐIỂM

……

……

……

……

……

……

Ngày…….tháng…….năm…….

Giảng viên (kí tên)

MỤC LỤC

PHẦN MỞ ĐẦU 1
1. Lý do chọn đề tài 1
2. Mục tiêu nghiên cứu 1
3. Phương pháp nghiên cứu 2
PHẦN NỘI DUNG 3
CHƯƠNG I: CƠ SỞ TOÁN HỌC 3
1.1. Đại số tuyến tính cho biểu diễn đặc trưng 3
1.1.1. Vector hóa dữ liệu đầu vào 3
1.1.2. Phép biến đổi tuyến tính qua Ma trận trọng số 3
1.1.3. Không gian con và Hạng của ma trận 3
1.2. Định nghĩa và tính chất của SVD 4
1.2.1. Định nghĩa toán học 4
1.2.2. Ý nghĩa hình học của phép biến đổi SVD: 4
1.2.3. Ví dụ minh họa 5
1.3. Bảo toàn tri thức và Chống lãng quên 5
1.4. Tinh chỉnh Hiệu quả Tham số 6
1.4.1. Rào cản của Tinh chỉnh Toàn bộ (Full Fine-Tuning) 6
1.4.2. Triết lý của PEFT và Mối liên hệ với Bài toán 6
1.5. Mạng Nơ-ron Tích chập (CNN) và biểu diễn đặc trưng 7
1.6. Kiến trúc Transformer và Cơ chế Self-Attention 8
1.6.1. Transformer Architure 8
1.6.2. Cơ chế Self-Attention (Q, K, V) 9
1.7. Contrastive Learning và SupCon 10
1.7.1. Học tương phản (Contrastive Learning) 10
1.7.2. Supervised Contrastive Learning (SupCon) 11
CHƯƠNG II: ỨNG DỤNG SVD BẢO TOÀN KHÔNG GIAN ĐẶC TRƯNG KHI TÁI HUẤN LUYỆN MÔ HÌNH 13
2.1. Dataset và tiền xử lý 13
2.1.1. Training Dataset 13
2.1.2. Tiền xử lý dữ liệu 14

2.2. Tổng quan phương pháp 15
2.3. Kiến trúc mô hình QHTD-CLIP 16
2.3.1. Backbone CLIP Vision Transformer 16
2.3.2. Phân rã SVD trong Self-Attention (SVD-PEFT) 17
2.3.3. Cosine Classifier và Asymetric Contractive Loss 19
2.3.4. Hàm mất mát tổng thể 22
CHƯƠNG III: THIẾT LẬP THỰC NGHIỆM VÀ KẾT QUẢ ĐÁNH GIÁ 24
3.1. Thiết lập thực nghiệm và giao thức đánh giá 24
3.2. Phân tích hiệu suất tổng quát hóa ngoại miền 24
3.3. Phân tích hiệu suất nội miền 25
KẾT LUẬN 26
TÀI LIỆU THAM KHẢO 27

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Ý nghĩa đầy đủ
AUC	Area Under the Curve (Diện tích dưới đường cong - Thước đo hiệu suất)
CLIP	Contrastive Language-Image Pre-training
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
PEFT	Parameter-Efficient Fine-Tuning (Tinh chỉnh hiệu quả tham số)
SVD	Singular Value Decomposition (Phân rã giá trị kỳ dị)
ViT	Vision Transformer

DANH MỤC HÌNH ẢNH

Hình 1.1: Minh họa Phân rã giá trị kỳ dị của một ma trận 4
Hình 1.2: Kiến trúc mạng CNN cho bài toán phân loại 7
Hình 1.3: Kiến trúc Transformer 8
Hình 1.4: Block Self - Attention 9
Hình 2.1: Các tập ảnh của từng datasets 13
Hình 2.2: Pipeline tiền xử lý dữ liệu(nguồn từ DeepfakeBench [11]) 14
Hinh 2.3: Pipeline của mô hình QHTD-CLIP 15
Bảng 3.1: So sánh hiệu suất Video AUC (%) trên các tập dữ liệu ngoại miền 24
Bảng 3.2: Hiệu suất AUC (%) trên các kỹ thuật thao túng nội miền (FF++) 25

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Sự bùng nổ của các mô hình tạo sinh như GAN và Diffusion Models đã khiến các kỹ thuật giả mạo khuôn mặt đạt đến độ chân thực chưa từng có, đặt ra thách thức lớn cho các hệ thống nhận diện. Hiện nay, hướng tiếp cận hiệu quả nhất là tận dụng các mô hình nền tảng thị giác khổng lồ như CLIP để trích xuất đặc trưng toàn cục. Tuy nhiên, việc tinh chỉnh toàn bộ tham số các mô hình này để học dấu vết giả mạo thường dẫn đến hiện tượng lãng quên tri thức và hiện tượng bất đối xứng.

Một vấn đề cốt lõi khác nằm ở bản chất đa dạng của các phương pháp sinh ảnh giả. Mỗi kỹ thuật như Deepfakes, FaceSwap hay Diffusion-based synthesis tạo ra những dấu vết giả mạo khác nhau về mặt tần số, cấu trúc hình học và phân bố thống kê. Các phương pháp trước đây thường học cách phân biệt thật–giả dựa trên các dấu hiệu đặc trưng của từng loại giả mạo cụ thể trong tập huấn luyện. Điều này vô tình khiến mô hình bị lệ thuộc vào các "pattern" cục bộ mang tính đặc thù, thay vì học được các đặc trưng bất biến (invariant features) của ảnh giả nói chung. Hệ quả là khi gặp các loại giả mạo chưa từng xuất hiện, hiệu suất suy giảm nghiêm trọng do thiếu khả năng tổng quát hóa.

Theo góc nhìn toán học, khi mô hình học vẹt các mẫu giả mạo trong tập huấn luyện, không gian đặc trưng của nó bị bóp méo và suy biến thành một không gian có hạng thấp, làm giới hạn nghiêm trọng khả năng tổng quát hóa trên các tập dữ liệu chưa từng thấy.

Để giải quyết điểm nghẽn này, bài toán đặt ra là làm sao để mô hình vừa học được các đặc trưng giả mạo mới, vừa bảo toàn được cấu trúc không gian tri thức nguyên bản. Phân rã giá trị kỳ dị (SVD), một công cụ nền tảng của đại số tuyến tính, cung cấp một giải pháp toán học triệt để cho vấn đề này. SVD cho phép phân rã không gian trọng số thành các không gian con trực giao, qua đó đóng băng các thành phần chính và chỉ tinh chỉnh trên phần dư để nạp thêm tri thức giả mạo.

2. Mục tiêu nghiên cứu

Đề tài hướng tới các mục tiêu cốt lõi sau:

- Hệ thống hóa kiến thức đại số tuyến tính về SVD, xấp xỉ ma trận hạng thấp, và tính chất trực giao của các không gian con.

- Trình bày cách thức biểu diễn trọng số của các lớp Self-Attention trong mạng Transformer dưới dạng xấp xỉ xấp xỉ hạng r thông qua SVD.
- Giải thích bằng công thức toán học và phân tích thực nghiệm cách SVD đóng vai trò như một "mỏ neo" hình học , giúp tách biệt không gian ngữ nghĩa và không gian giả mạo, từ đó tăng cường độ ổn định và cải thiện chỉ số AUC trong các kịch bản đánh giá chéo miền.

3. Phương pháp nghiên cứu

- Phương pháp phân tích lý thuyết: Dựa trên các định lý của đại số tuyến tính để chứng minh tính hợp lý của việc phân rã ma trận trọng số $W \in R^{n*n}$ thành các thành phần nguyên bản và thành phần dư thừa ΔW. Phân tích các hàm mất mát ràng buộc trực giao để duy trì tính độc lập giữa hai không gian.
- Phương pháp tổng hợp và mô hình hóa: Tổng hợp lý thuyết toán học vào kiến trúc của các mô hình Deep Learning hiện đại, cụ thể là lồng ghép SVD vào khung tinh chỉnh hiệu quả tham số (PEFT).

PHẦN NỘI DUNG

CHƯƠNG I: CƠ SỞ TOÁN HỌC

1.1. Đại số tuyến tính cho biểu diễn đặc trưng

1.1.1. Vector hóa dữ liệu đầu vào

Một mẫu dữ liệu (như ảnh khuôn mặt) sau khi trích xuất đặc trưng được biểu diễn dưới dạng một vectơ cột x trong không gian n chiều:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{\mathbb{n}}$$

Khi xử lý đồng thời một tập hợp m mẫu dữ liệu (batch), ta thu được ma trận dữ liệu X:

$$X = \left[x^{(1)}, x^{(2)}, \dots, x^{(m)}\right] \in \mathbb{R}^{\mathbb{n}\times\mathbb{m}}$$

1.1.2. Phép biến đổi tuyến tính qua Ma trận trọng số

Quá trình lan truyền tín hiệu trong mạng nơ-ron là chuỗi các phép nhân ma trận. Xét một lớp tuyến tính có ma trận trọng số $W \in \mathbb{R}^{d\times\mathrm{n}}$, phép biến đổi một vectơ đầu vào x sang không gian đặc trưng mới $y \in \mathbb{R}^d$ được định nghĩa là:

$$y = Wx + b$$

Trong đó $b \in \mathbb{R}^{\mathbb{d}}$ là vectơ chệch. Về mặt toán học, y là một tổ hợp tuyến tính của các cột trong ma trận W, với các hệ số tổ hợp chính là các thành phần của vectơ x.

1.1.3. Không gian con và Hạng của ma trận

Hạng của ma trận trọng số, ký hiệu là *rank(W)*, quyết định số chiều tối đa của không gian đặc trưng mà mô hình có thể biểu diễn.

- **Hiện tượng suy biến:** Khi mô hình bị "lãng quên tri thức", ma trận W có xu hướng chuyển dịch sang trạng thái hạng thấp (*low-rank*), làm mất đi tính đa dạng của không gian đặc trưng nguyên bản.
- **Giải pháp hình học:** Việc bảo toàn không gian đặc trưng chính là duy trì cấu trúc các vectơ cơ sở của ma trận W thông qua các phép biến đổi trực giao.

1.2. Định nghĩa và tính chất của SVD

Phân rã giá trị kỳ dị là sự mở rộng của phép phân rã trị riêng cho các ma trận không vuông. Đây là công cụ mạnh mẽ nhất của đại số tuyến tính để phân tích cấu trúc của một toán tử tuyến tính.

1.2.1. Định nghĩa toán học

Xét một ma trận có trọng số bất kỳ $W \in \mathbb{R}^{m \times m}$ có hạng rank là k. Phép phân rã SVD biểu diễn W dưới dạng tích của ba a trận đặc biệt:

$$W = U\Sigma V^T = \sum_{i=1}^{n} \sigma_i u_i v_i^T$$

Trong đó:

- $U \in \mathbb{R}^{m \times m}$ là ma trận trực giao ($U^T U = I$) chứa các vector kỳ dị trái u_i. Các vector này thực chất là các vector riêng của ma trận WW^T.
- $V \in \mathbb{R}^{m \times m}$ là ma trận trực giao ($V^T V = I$) chứa các vector kỳ dị phải v_i. Các vectơ này là vectơ riêng của ma trận $W^T W$.
- $\Sigma \in \mathbb{R}^{m \times m}$ là ma trận đường chéo chứa các giá trị kỳ dị σ_i. Các giá trị này được tính bằng căn bậc hai của các trị riêng của $W^T W$ (tức là $\sigma_i = \sqrt{\lambda_i}$) và được sắp xếp giảm dần $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n \geq 0$

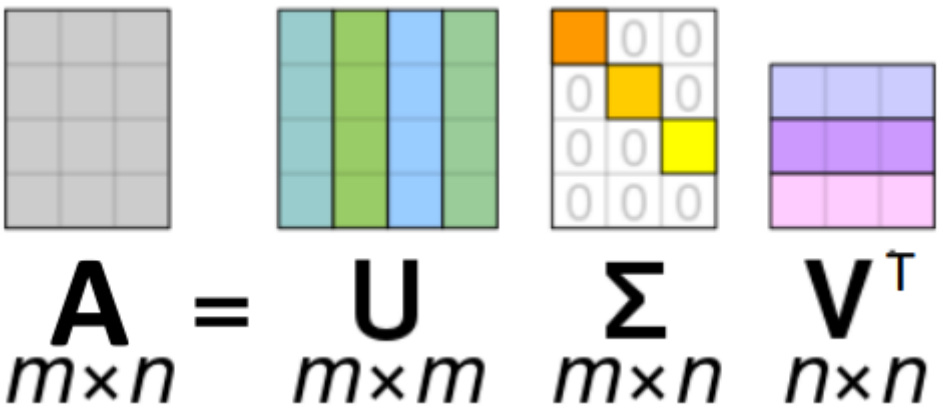

Hình 1.1: Minh họa Phân rã giá trị kỳ dị của một ma trận

1.2.2. Ý nghĩa hình học của phép biến đổi SVD:

Phép nhân một vector đầu vào x với ma trận trọng số W (tức là $y = Wx$) có thể được hiểu thông qua ba bước biến đổi hình học tuần tự: $x \rightarrow V^T x \rightarrow \Sigma(V^T x) \rightarrow U(\Sigma V^T x)$

1. **<u>Phép quay thứ nhất (V^T):</u>** Chiếu vector đầu vào x lên hệ cơ sở trực chuẩn mới của không gian đầu vào mà không làm thay đổi độ lớn của nó.
2. **<u>Phép co giãn (Σ):</u>** Kéo giãn hoặc thu nhỏ các thành phần của vector dọc theo các trục tọa độ mới với hệ số tỷ lệ chính là các giá trị kỳ dị σ_i. Độ lớn của σ_i phản ánh lượng phương sai hoặc mức độ thông tin mà hướng đi tương ứng nắm giữ.
3. **<u>Phép quay thứ hai (U):</u>** Đưa vector đã được co giãn sang hệ cơ sở trực chuẩn của không gian đầu ra.

1.2.3. Ví dụ minh họa

Giả sử ta trích xuất được một ma trận trọng số kích thước nhỏ $W = \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix}$.

Quy trình tìm SVD thực hiện như sau:

Bước 1: Tính $W^T W = \begin{bmatrix} 1 & 2 \\ -2 & -1 \end{bmatrix} \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix} = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}$

Bước 2: Tìm trị riêng giải $\det(W^T W - \lambda I) = 0 \Rightarrow (5-\lambda)^2 - 16 = 0$.

Ta có $\lambda_1 = 9$ và $\lambda_2 = 1$.

Vậy $\sigma_1 = 3, \sigma_2 = 1$.

Ma trận $\Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$

Bước 3: Tìm vector riêng trực chuẩn để lập V và U

$V = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$, và dùng công thức $u_i = \frac{1}{\sigma_i} W v_i$ ta được

$U = \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$

Bước 4: Xấp xỉ hạng 1 (Mỏ neo tri thức đóng băng):

$$W_1 = u_1 \sigma_1 v_1^T = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix} [3] \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} 1.5 & -1.5 \\ 1.5 & -1.5 \end{bmatrix}$$

1.3. Bảo toàn tri thức và Chống lãng quên

Khi tái huấn luyện (fine-tuning) một mô hình tiền huấn luyện trên tập dữ liệu mới (ví dụ: phát hiện Deepfake), việc cập nhật toàn bộ ma trận W thường làm hỏng cấu trúc hình học ban đầu, dẫn đến hiện tượng lãng quên tri thức.

SVD cho phép ta thực hiện chiến lược đóng băng chọn lọc:

1. Sử dụng r thành phần kỳ dị lớn nhất (u_i, σ_i, v_i) để tạo thành mỏ neo tri thức W_r.
2. Chỉ cho phép một phần dư tối ưu hóa cập nhật trên không gian phần dư $\Delta W = W - W_r$.

   Điều này đảm bảo mô hình học được các dấu vết giả mạo mới mà không làm mất đi khả năng nhận diện các đặc trưng cơ bản đã học từ trước.

1.4. Tinh chỉnh Hiệu quả Tham số

1.4.1. Rào cản của Tinh chỉnh Toàn bộ (Full Fine-Tuning)

Khi triển khai các mô hình nền tảng (Foundation Models) có quy mô tham số khổng lồ như CLIP vào các bài toán chuyên biệt như phát hiện ảnh giả khuôn mặt, chiến lược truyền thống thường là cập nhật lại toàn bộ trọng số mạng (Full Fine-Tuning). Tuy nhiên, phương pháp này đối mặt với hai rào cản lớn:

- **Hiện tượng lãng quên tri thức (Catastrophic Forgetting):** Việc sử dụng một tập dữ liệu chuyên biệt nhỏ để cập nhật một không gian trọng số quá lớn khiến mô hình mất đi các tri thức tổng quát đã học được từ giai đoạn tiền huấn luyện.
- **Suy biến không gian đặc trưng:** Không gian đặc trưng vốn đa dạng và có hạng cao ($higher - ranked$) của mô hình ban đầu bị bóp méo, suy biến thành hạng thấp ($low - ranked$), làm giới hạn nghiêm trọng khả năng tổng quát hóa trên các tập dữ liệu ngoài phân phối ($out - of - distribution$).
- **Chi phí tài nguyên và rào cản phần cứng:** Quá trình tinh chỉnh toàn bộ đòi hỏi việc lưu trữ và tính toán gradient cho hàng trăm triệu tham số, dẫn đến yêu cầu khắt khe về bộ nhớ video (VRAM) và năng suất tính toán của GPU. Điều này không chỉ kéo dài thời gian huấn luyện mà còn gây khó khăn cho việc triển khai trên các hệ thống có tài nguyên hạn chế.

1.4.2. Triết lý của PEFT và Mối liên hệ với Bài toán

Triết lý cốt lõi của **PEFT** là chỉ cập nhật một tập hợp nhỏ các tham số bổ trợ hoặc các thành phần được lựa chọn kỹ lưỡng, trong khi giữ cố định ($freezing$) phần lớn trọng số của mô hình tiền huấn luyện.

- **Tối ưu hóa hiệu suất tính toán:** Thay vì điều chỉnh toàn bộ ma trận trọng số, PEFT tập trung vào các cấu trúc hạng thấp hoặc các lớp đệm (adapter). Điều này giúp giảm thiểu đáng kể khối lượng tính toán, rút ngắn chu kỳ huấn luyện và cho phép mô hình đạt được hiệu suất tối ưu mà không cần đến các hệ thống siêu tính toán đắt đỏ.

- **Bảo tồn đặc trưng và tính tổng quát:** Bằng cách giữ nguyên phần lớn "tri thức nền tảng", PEFT ngăn chặn sự xô lệch không gian đặc trưng. Đối với bài toán phát hiện Deepfake, điều này cực kỳ quan trọng vì nó cho phép mô hình vừa giữ được khả năng nhận diện các thuộc tính vật lý của ảnh thật, vừa học thêm các dấu vết giả mạo mới thông qua một không gian tham số tinh gọn.
- **Mối liên hệ với giải pháp SVD:** Trong nghiên cứu này, SVD được ứng dụng như một kỹ thuật PEFT tiên tiến. Thay vì thêm các module bên ngoài, ta thực hiện "phẫu thuật" trực tiếp ma trận trọng số để tách biệt thành phần chính và thành phần dư thừa, giúp việc tinh chỉnh trở nên chính xác và hiệu quả hơn về mặt toán học.

1.5. Mạng Nơ-ron Tích chập (CNN) và biểu diễn đặc trưng

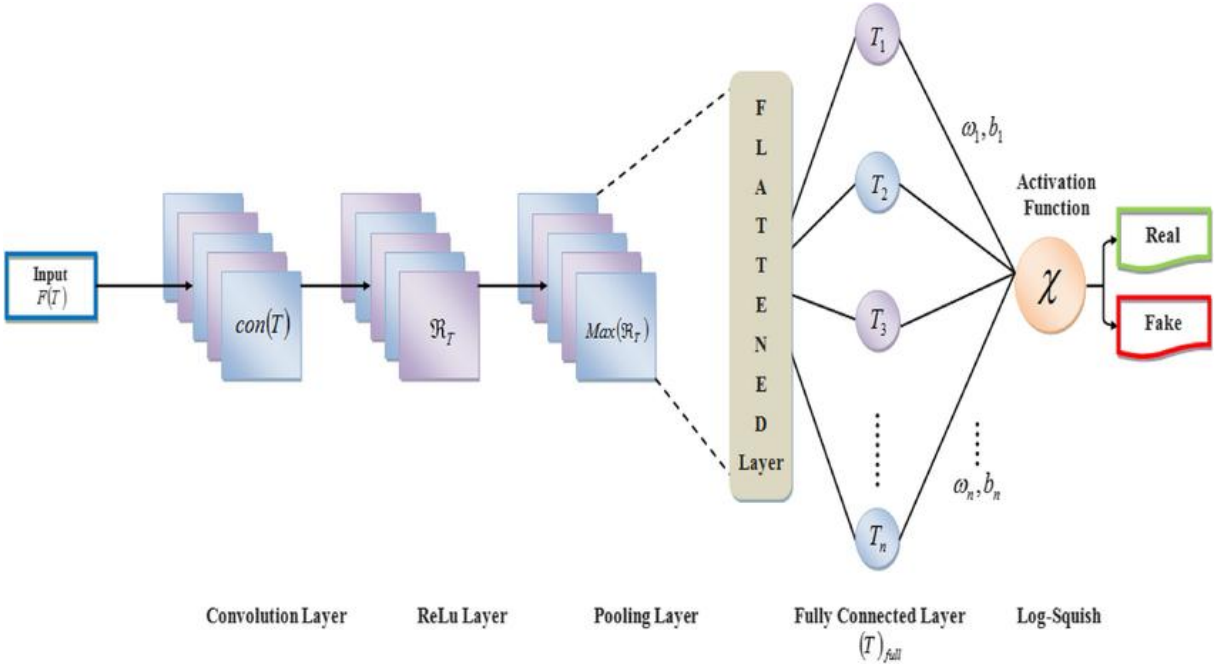

Hình 1.2: Kiến trúc mạng CNN cho bài toán phân loại

Cơ sở lý thuyết của CNN

CNN là nền tảng của thị giác máy tính cổ điển, hoạt động dựa trên phép toán tích chập rời rạc. Giả sử ta có một ảnh đầu vào X (biểu diễn dưới dạng ma trận 2D) và một bộ lọc (kernel/filter) K kích thước m x n, phép tích chập sinh ra bản đồ đặc trưng (feature map) Y được định nghĩa bằng công thức:

$$Y[i,j] = (X * K)[i,j] = \sum_{u=0}^{m-1} \sum_{v=0}^{n-1} X[i-u, j-v] K[u,v]$$

Bản chất của phép toán này là trượt bộ lọc K trên toàn bộ bức ảnh X để tính tổng các tích vô hướng cục bộ. Tiếp theo đó, giá trị này sẽ đi qua hàm kích hoạt phi tuyến (thường là ReLU, $f(x) = \max(0, x)$) và cơ chế gộp (Pooling) để giảm chiều dữ liệu.

1.6. Kiến trúc Transformer và Cơ chế Self-Attention

1.6.1. Transformer Architure

Mô hình Transformer gồm hai phần: Encoder (Bộ mã hóa) và Decoder (Bộ giải mã).

- **Encoder**: Đọc và hiểu ngữ cảnh của văn bản đầu vào. Nó có nhiều lớp giống nhau, mỗi lớp có hai nhánh con: Multi-Head Self-Attention và Feed-Forward Neural Network.
- **Decoder**: Nhận thông tin từ Encoder để tạo ra kết quả đầu ra (ví dụ: dịch sang ngôn ngữ khác). Decoder có thêm lớp Masked Multi-Head Attention để ngăn mô hình "nhìn trước" các từ trong tương lai khi đang huấn luyện.

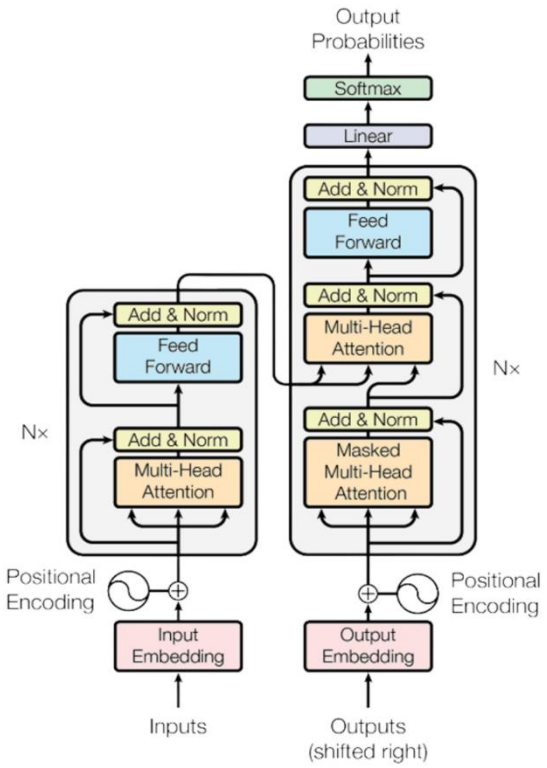

Hình 1.3: Kiến trúc Transformer

- **Positional encoding**:

Do Transformer không sử dụng các cấu trúc tuần tự (RNN) hay tích chập (CNN), mô hình mặc định có tính chất "bất biến với phép hoán vị". Để khôi phục thông tin về thứ tự của các token trong chuỗi, một vectơ mã hóa vị trí PE được cộng trực tiếp vào vectơ nhúng đầu vào (Input Embedding) E:

$$Z = E + PE$$

Trong đó, các giá trị của PE thường được xác định bởi các hàm lượng giác có tần số khác nhau, cho phép mô hình nắm bắt được vị trí tương đối và tuyệt đối giữa các phần tử trong không gian.

- **Lớp Normalization**: Trong sơ đồ cấu trúc, lớp "Norm" thực hiện nhiệm vụ chuẩn hóa dữ liệu đầu ra của các khối Multi-head Attention và Feed-Forward. Về mặt toán học, Layer Normalization giúp điều chỉnh phân phối của các giá trị kích hoạt về trạng thái ổn

định (trung bình bằng 0 và phương sai bằng 1), từ đó tăng tốc độ hội tụ của thuật toán tối ưu hóa và giảm thiểu hiện tượng bùng nổ hoặc mất mát gradient.

- **Kết nối Residual**: Kết nối phần dư (được ký hiệu là "Add" trong khối "Add & Norm") đóng vai trò thiết lập một "đường truyền tắt" cho dòng tín hiệu. Đầu ra của một khối lớp sẽ là tổng của đầu vào x và hàm biến đổi $F(x)$:

$$\text{Output} = \text{LayerNorm}\big(x + F(x)\big)$$

Cơ chế này cho phép các gradient có thể truyền ngược trực tiếp qua các lớp mà không bị suy giảm quá mức, từ đó hỗ trợ việc huấn luyện các mạng nơ-ron có độ sâu lớn (nhiều lớp chồng lên nhau).

- **Khối Feed-Forward**: Sau mỗi khối Attention, dữ liệu sẽ đi qua mạng Feed-Forward bao gồm hai phép biến đổi tuyến tính kết hợp với một hàm kích hoạt phi tuyến (thường là ReLU hoặc GeLU):

$$FFN(x) = \max(0, xW_1 + b_1)\, W_2 + b_2$$

Nếu cơ chế Attention chịu trách nhiệm trích xuất mối tương quan ngữ nghĩa giữa các token, thì khối FFN đóng vai trò như một bộ xử lý cục bộ, thực hiện việc ánh xạ và biến đổi đặc trưng để làm giàu thêm thông tin biểu diễn cho mỗi vị trí trước khi chuyển sang lớp tiếp theo.

1.6.2. Cơ chế Self-Attention (Q, K, V)

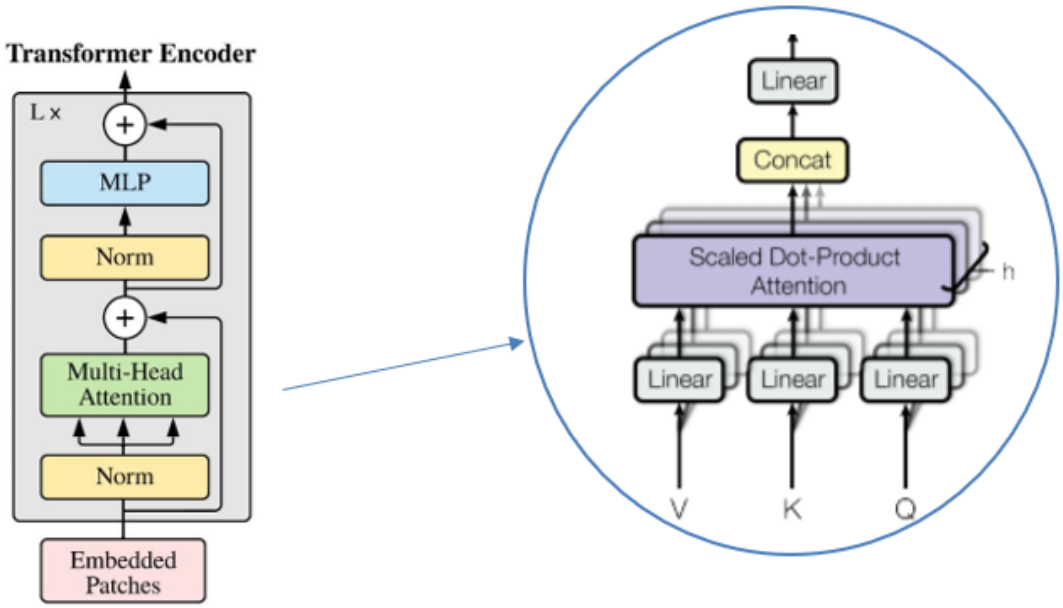

Hình 1.4: Block Self - Attention

Block Self – Attention: Cơ chế này sử dụng ba ma trận đầu vào được biến đổi từ các patch ảnh: Query (Q), Key (K), và Value (V). Công thức chuẩn (Scaled Dot-Product Attention) là:

$$\mathrm{Attention}(\mathrm{Q}, \mathrm{K}, \mathrm{V}) = \mathrm{softmax}\left(\frac{\mathrm{QK}^{\mathrm{T}}}{\sqrt{\mathrm{d_k}}}\right)\mathrm{V}$$

Trong đó:

- **Q:** Đại diện cho patch hiện tại đang cần tìm kiếm thông tin.
- **K:** Đại diện cho tất cả các patch trong ảnh để so khớp với Query.
- **V:** Chứa thông tin thực tế của các patch.
- $\mathrm{d_k}$: Kích thước (số chiều) của vector Key, dùng để chuẩn hóa (chia cho $\sqrt{\mathrm{d_k}}$) giúp gradient ổn định hơn khi tập huấn.
- **Softmax:** Chuyển đổi các điểm số tương quan thành trọng số xác suất sao cho tổng bằng 1.

Ví dụ minh họa:

Bước 1: Khởi tạo dữ liệu đầu vào

Giả sử ma trận đầu vào $X_{2\times 3}$ là: $X = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{bmatrix}$

Dòng 1: Vector đại diện cho Token 1

Dòng 2: Vector đại diện cho Token 2

Bước 2: Khởi tạo các ma trận trọng số

Trong mô hình Transformer, các ma trận trọng số W_Q, W_K, W_V được khởi tạo ngẫu nhiên và học qua quá trình huấn luyện. Giả sử các ma trận trọng số (kích thước 3×3) là:

$$W_Q = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad W_K = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}, \quad W_V = \begin{bmatrix} 0 & 2 & 0 \\ 0 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Bước 3: Tính toán các ma trận $\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}$

Phép toán được thực hiện bằng cách nhân ma trận đầu vào X với từng ma trận trọng số:

Tính ma trận Query ($Q = X \cdot W_Q$): $$Q = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{bmatrix}\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 2 \\ 2 & 2 & 0 \end{bmatrix}$$

Tính ma trận Key ($K = X \cdot W_K$): $$K = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}$$

Tính ma trận Value ($V = X \cdot W_V$): $$V = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 0 & 2 & 0 \\ 0 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 6 & 0 \end{bmatrix}$$

Bước 4: Tính toán Score và Attention

Sau khi có Q, K, V, mô hình thực hiện tính toán ma trận trọng số chú ý (Attention Score) bằng tích vô hướng giữa Q và $K^\top$, sau đó chuẩn hóa qua hàm **softmax**:

$$\text{Score} = QK^\top = \begin{bmatrix} 1 & 0 & 2 \\ 2 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 6 \\ 6 & 4 \end{bmatrix}$$

Kết quả cuối cùng của lớp Attention là sự kết hợp giữa các trọng số này với ma trận V để trích xuất các thông tin quan trọng nhất từ hình ảnh.

1.7. Contrastive Learning và SupCon

1.7.1. Học tương phản (Contrastive Learning)

Contrastive Learning là một phương pháp học biểu diễn (representation learning) tập trung vào việc tổ chức lại cấu trúc của dữ liệu trong không gian đặc trưng. Mục tiêu cốt lõi của phương pháp này là học được một hàm ánh xạ sao cho các mẫu dữ liệu tương đồng (positive samples) được kéo lại gần nhau, trong khi các mẫu khác biệt (negative samples) bị đẩy ra xa nhau. Quá trình này giúp mô hình tự trích xuất được những đặc trưng cốt lõi và mang tính phân biệt cao mà không nhất thiết không cần nhãn thủ công.

Trong thực tế, học tương phản thường được triển khai dưới dạng học tự giám sát (self-supervised learning). Ở kịch bản này, mô hình không cần đến nhãn thủ công từ con người; thay vào đó, nó tự tạo ra các cặp mẫu dương bằng cách áp dụng các kỹ thuật tăng cường dữ liệu (data augmentation) lên cùng một ảnh gốc. Cách tiếp cận này mang lại ưu điểm vượt trội trong việc tận dụng nguồn dữ liệu khổng lồ chưa được gán nhãn, giúp mô hình học được những biểu diễn có tính tổng quát hóa cao và dễ dàng chuyển đổi sang các tác vụ hạ nguồn khác nhau.

Tuy nhiên, học tương phản truyền thống vẫn tồn tại những hạn chế đáng kể về mặt ngữ nghĩa. Do hoạt động dựa trên cơ chế tự giám sát, mô hình chỉ coi các biến thể của chính mẫu đó là "mẫu dương". Điều này dẫn đến một nhược điểm lớn: nếu hai mẫu dữ liệu khác nhau nhưng cùng thuộc một lớp đối tượng (ví dụ: hai bức ảnh chụp hai con

chó khác nhau), mô hình vẫn mặc định coi chúng là "mẫu âm" và cố gắng đẩy chúng ra xa nhau trong không gian đặc trưng. Việc thiếu đi thông tin về nhãn lớp khiến mô hình bỏ lỡ cơ hội tối ưu hóa sự gắn kết giữa các thực thể cùng loại, từ đó làm hạn chế khả năng phân loại chính xác. Đây chính là động lực chính dẫn đến sự ra đời của Supervised Contrastive Learning (SupCon) – một bước tiến giúp kết hợp sức mạnh của học tương phản với thông tin giám sát từ nhãn dữ liệu.

1.7.2. Supervised Contrastive Learning (SupCon)

Supervised Contrastive Learning (SupCon) là một mở rộng của Contrastive Learning trong thiết lập có giám sát, trong đó thông tin nhãn được sử dụng để xác định các cặp mẫu dương (positive) và âm (negative). Khác với phương pháp tự giám sát chỉ sử dụng một cặp dương cho mỗi mẫu, SupCon cho phép mỗi mẫu (anchor) có nhiều cặp dương tương ứng với tất cả các mẫu cùng lớp trong batch .

Cụ thể, xét một batch gồm N mẫu dữ liệu, sau khi áp dụng data augmentation ta thu được $2N$ mẫu. Gọi z_i:

$$P(i) = \{p \neq i \mid y_p = y_i\}$$

Và tập tất cả các mẫu còn lại trong batch là:

$$A(i) = \{\, a \neq i \,\}$$

Hàm mất mát SupCon được định nghĩa như sau:

$$L_{sup} = \sum_{i \in I} -\frac{1}{|P(i)|} \sum_{p \in P(i)} \ln\left(\frac{e^{(z_i \cdot z_p)/\tau}}{\sum_{a \in A(i)} e^{(z_i \cdot z_a)/\tau}}\right)$$

Trong đó:

- $\boldsymbol{z_i \cdot z_p}$**:** tích vô hướng giữa anchor và positive (thường tương đương cosine similarity do đã chuẩn hóa)
- $\boldsymbol{\tau}$**:** tham số nhiệt độ giúp điều chỉnh độ "sắc" của phân phối
- $\boldsymbol{|\, P(i) \,|}$**:** số lượng positive của anchor i

Hàm mất mát này có mục tiêu kéo các vector đặc trưng của cùng một lớp lại gần nhau trong không gian embedding, đồng thời đẩy các vector của các lớp khác ra xa. Việc sử dụng nhiều positive cho mỗi anchor giúp không gian đặc trưng hình thành các cụm (cluster) rõ ràng hơn so với contrastive learning tự giám sát

Một ưu điểm quan trọng của SupCon là khả năng tận dụng đồng thời nhiều positive và nhiều negative trong cùng một batch, từ đó cải thiện hiệu quả học biểu diễn mà không cần kỹ thuật hard negative mining phức tạp. Ngoài ra, do sử dụng embedding đã chuẩn hóa, hàm mất mát này tương đương với việc tối ưu trên không gian siêu cầu (hypersphere), giúp tăng tính ổn định và khả năng tổng quát hóa của mô hình.

CHƯƠNG II: ỨNG DỤNG SVD BẢO TOÀN KHÔNG GIAN ĐẶC TRƯNG KHI TÁI HUẤN LUYỆN MÔ HÌNH

2.1. Dataset và tiền xử lý

2.1.1. Training Dataset

Mô hình được huấn luyện trên bộ dữ liệu FaceForensics++ (FF++) [4], một trong những bộ dữ liệu chuẩn và được sử dụng rộng rãi trong lĩnh vực phát hiện ảnh giả mạo khuôn mặt. Bộ dữ liệu này cung cấp một tập hợp phong phú các mẫu dữ liệu, bao gồm 720 video thật được thu thập từ nền tảng YouTube, cùng với 2.880 video giả mạo được tạo ra thông qua bốn kỹ thuật thao túng khuôn mặt phổ biến, bao gồm: Deepfakes (DF), Face2Face (F2F), FaceSwap (FS) và NeuralTextures (NT). Mỗi phương pháp giả mạo đóng góp 720 video, đảm bảo sự cân bằng giữa các loại kỹ thuật sinh ảnh.

Hình 2.1: Các tập ảnh của từng datasets

Các video trong FF++ được xây dựng với nhiều mức độ xử lý khác nhau nhằm phản ánh các điều kiện nén và truyền tải thực tế. Trong nghiên cứu này, phiên bản dữ liệu nén với mức chất lượng c23 được lựa chọn nhằm đảm bảo tính nhất quán với các công trình trước đó. Mức nén này được xem là sự cân bằng hợp lý giữa dung lượng lưu trữ và chất lượng hình ảnh, đồng thời vẫn giữ được các đặc trưng tinh vi liên quan đến dấu vết giả mạo.

Việc sử dụng FF++ không chỉ giúp mô hình học được các đặc trưng giả mạo từ nhiều kỹ thuật khác nhau mà còn tạo tiền đề cho việc đánh giá khả năng tổng quát hóa trên các tập dữ liệu ngoài phân phối trong các thí nghiệm tiếp theo.

2.1.2. Tiền xử lý dữ liệu

Quy trình tiền xử lý dữ liệu được xây dựng dựa trên phương pháp của DeepfakeBench [11]. Từ mỗi video đầu vào, một tập gồm 32 khung hình (frames) được trích xuất tại các vị trí phân bố đều theo thời gian, nhằm đảm bảo bao phủ toàn bộ nội dung video và giảm thiểu sai lệch do lựa chọn khung hình cục bộ.

Trên mỗi khung hình, khuôn mặt được phát hiện bằng thuật toán phát hiện khuôn mặt dựa trên thư viện Dlib. Trong trường hợp xuất hiện nhiều khuôn mặt, chỉ khuôn mặt có diện tích lớn nhất được giữ lại nhằm đảm bảo tính nhất quán và giảm nhiễu từ các đối tượng phụ. Sau bước phát hiện, khuôn mặt được căn chỉnh dựa trên các điểm mốc (facial landmarks) để chuẩn hóa về mặt hình học.

Để giữ lại đầy đủ các vùng thông tin quan trọng xung quanh khuôn mặt, bounding box được mở rộng với hệ số 1.3× trước khi tiến hành cắt (crop). Vùng ảnh sau đó được đưa về kích thước chuẩn 224×224 nhằm phù hợp với đầu vào của kiến trúc Vision Transformer trong mô hình.

Sau cùng, toàn bộ các ảnh sau tiền xử lý được lưu dưới định dạng không mất dữ liệu (lossless) nhằm tránh phát sinh thêm nhiễu do nén, từ đó đảm bảo tính toàn vẹn của các đặc trưng phục vụ cho quá trình huấn luyện.

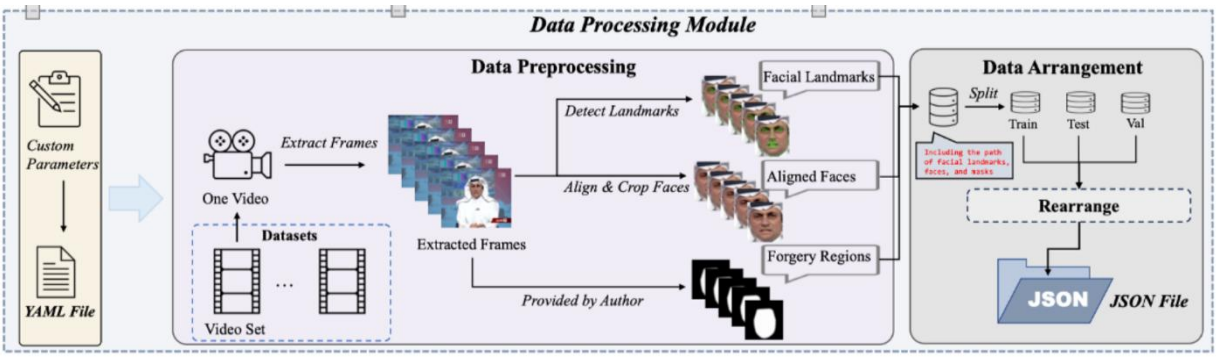

Hình 2.2: Pipeline tiền xử lý dữ liệu(nguồn từ DeepfakeBench [11])

2.2. Tổng quan phương pháp

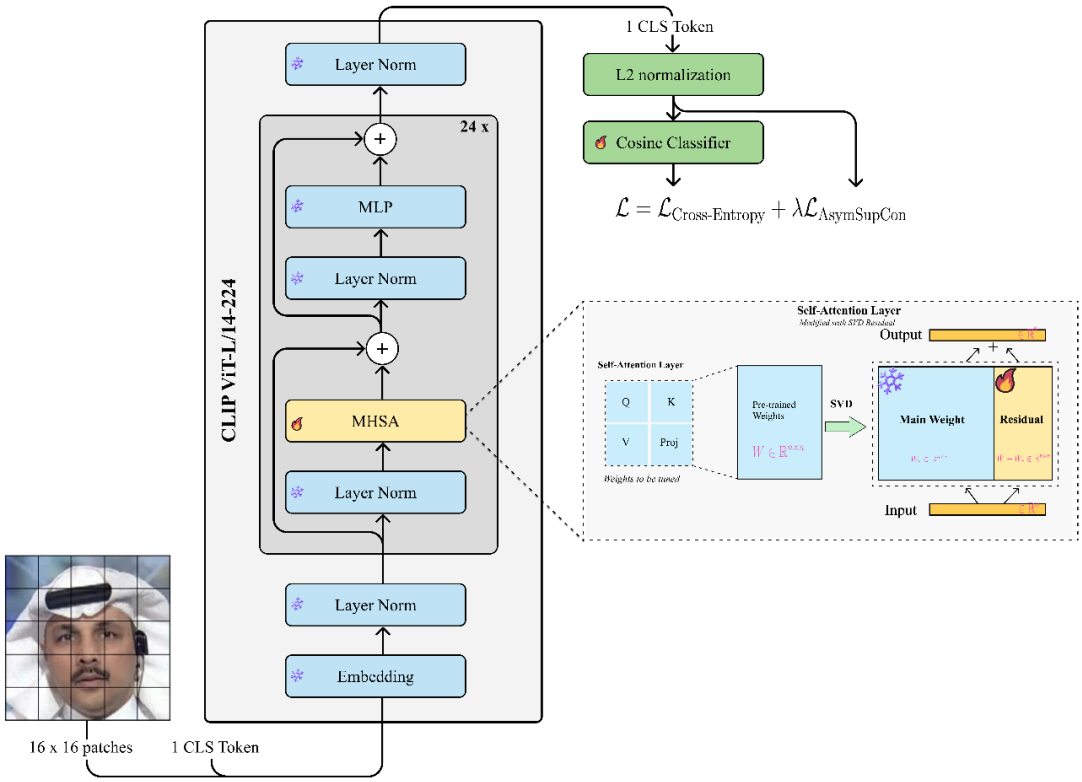

Hình 2.3: Pipeline của mô hình QHTD-CLIP

Phương pháp đề xuất QHTD-CLIP này được phát triển dựa trên mô hình Effort [14]. Cụ thể, QHTD-CLIP xây dựng trên nền tảng Vision Transformer của mô hình CLIP, với mục tiêu bảo toàn không gian đặc trưng tiền huấn luyện đồng thời học hiệu quả các dấu vết giả mạo. Như minh họa trong Hình 3.2, pipeline tổng thể bao gồm ba thành phần chính: trích xuất đặc trưng bằng backbone CLIP ViT-L/14-224 [12], phân rã trọng số bằng SVD trong các lớp self-attention, và tối ưu hóa bằng bộ phân loại cosine kết hợp hàm mất mát bất đối xứng. Trong mô hình, các lớp self-attention được phân rã bằng SVD để tách biệt trọng số thành thành phần chính (được giữ cố định) và phần dư (được tối ưu), giúp bảo toàn tri thức tiền huấn luyện và hạn chế suy biến không gian đặc trưng.

Đặc trưng đầu ra được chuẩn hóa L2 và đưa vào bộ phân loại cosine. Quá trình huấn luyện sử dụng kết hợp hàm mất mát cross-entropy và hàm mất mát Asymmetric SupCon, trong đó các mẫu ảnh thật được kéo lại gần nhau và các mẫu giả được đẩy ra xa, giúp tăng cường khả năng phân biệt và tổng quát hóa của mô hình.

2.3. Kiến trúc mô hình QHTD-CLIP

Kiến trúc QHTD-CLIP (Quadratic Hyperspherical Transfer Decomposition CLIP) được xây dựng nhằm kết hợp giữa mô hình nền CLIP [12], phân rã SVD bảo toàn không gian đặc trưng, và học metric trên mặt cầu siêu. Mục tiêu là vừa giữ được tri thức tiền huấn luyện, vừa học hiệu quả các dấu vết giả mạo.

Tổng thể, mô hình gồm ba thành phần chính:

(1) Backbone trích xuất đặc trưng,

(2) Cơ chế phân rã SVD trong self-attention,

(3) Bộ phân loại cosine và chiến lược tối ưu hóa bằng Asymetric Contractive.

2.3.1. Backbone CLIP Vision Transformer

Trong mô hình QHTD-CLIP, backbone được xây dựng dựa trên CLIP ViT-L/14-224 [12] nhằm trích xuất đặc trưng ảnh ở mức ngữ nghĩa cao.

Ảnh đầu vào kích thước $\mathbf{224 \times 224}$ được chia thành các patch $\mathbf{16 \times 16}$, tạo thành 196 patch. Mỗi patch được ánh xạ thành vector embedding và kết hợp với CLS token để biểu diễn toàn bộ ảnh. Sau đó, thông tin vị trí được bổ sung thông qua positional encoding.

Chuỗi embedding được đưa qua nhiều block Transformer, mỗi block gồm hai thành phần chính:

***Multi-Head Self-Attention (MHSA)*:** mô hình hóa quan hệ giữa các patch thông qua:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

***MLP (Feed-Forward Network)*:** tăng khả năng biểu diễn phi tuyến.

Mỗi block sử dụng residual connection và LayerNorm để ổn định huấn luyện.

Sau khi đi qua toàn bộ mạng, vector tương ứng với CLS token được lấy làm đặc trưng toàn cục:

$$\mathrm{f} = \mathrm{ViT}(x)_{[\mathrm{CLS}]} \in \mathbb{R}^{1024}$$

Vai trò: Backbone CLIP cung cấp không gian đặc trưng giàu thông tin và khả năng tổng quát hóa mạnh. Trong QHTD-CLIP, backbone không được fine-tune toàn bộ mà chỉ được điều chỉnh cục bộ thông qua SVD ở các lớp self-attention, giúp bảo toàn tri thức tiền huấn luyện.

2.3.2. Phân rã SVD trong Self-Attention (SVD-PEFT)

Trong kiến trúc Transformer, các phép biến đổi tuyến tính trong cơ chế Self-Attention được thực hiện thông qua các ma trận trọng số $W_Q, W_K, W_V \in \mathbb{R}^{d\times d}$. Đối với backbone CLIP ViT-L/14 được sử dụng trong mô hình QHTD-CLIP, kích thước không gian đặc trưng là $d = 1024$. Do đó, mỗi token đầu vào (bao gồm cả các patch và CLS token) được biểu diễn dưới dạng một vectơ $x \in \mathbb{R}^{1024}$.

Không gian $\mathbb{R}^{1024}$ này không phải là một không gian ngẫu nhiên, mà là một không gian biểu diễn đã được tiền huấn luyện trên quy mô lớn, chứa đựng các đặc trưng ngữ nghĩa phong phú như cấu trúc hình học, kết cấu và ngữ cảnh thị giác. Nói cách khác, đây chính là không gian tri thức nền (semantic feature space) của mô hình.

Phân rã SVD của ma trận trọng số

Xét một ma trận trọng số bất kỳ trong Self-Attention:

$$W \in \mathbb{R}^{1024\times 1024}$$

Ta áp dụng phân rã giá trị kỳ dị:

$$W = U\Sigma V^T$$

trong đó $\Sigma = \mathrm{diag}(\sigma_1, \dots, \sigma_{1024})$ với:

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{1024} \geq 0$$

Các giá trị kỳ dị lớn tương ứng với các hướng mang nhiều thông tin nhất trong không gian đặc trưng.

Tách không gian đặc trưng theo phổ kỳ dị

Dựa trên SVD, ta phân tách ma trận W thành hai thành phần:

$$W = W_{\text{main}} + W_{\text{res}}$$

với:

$$W_{\text{main}} = \sum_{i=1}^{1023} \sigma_i\, u_i v_i^T \qquad W_{\text{res}} = \sigma_{1024} u_{1024} v_{1024}^T$$

Như vậy:

- W_{main} là xấp xỉ hạng 1023, chứa gần như toàn bộ năng lượng của ma trận
- W_{res} là thành phần hạng 1 (rank-1 residual)

Cơ chế SVD-PEFT

Trong quá trình tái huấn luyện, mô hình không cập nhật toàn bộ W, mà chỉ tối ưu trên phần dư:

$$W' = W_{\text{main}} + \Delta W$$

trong đó:

$$\Delta W = U_{\text{res}} \tilde{\Sigma} V_{\text{res}}^T$$

Thành phần W_{main} được giữ cố định nhằm bảo toàn tri thức tiền huấn luyện, trong khi ΔW đóng vai trò là phần thích nghi với dữ liệu mới.

Phân tích vai trò của không gian 1024 chiều

Không gian $\mathbb{R}^{1024}$có thể được hiểu như một không gian Hilbert cao chiều, trong đó mỗi chiều tương ứng với một hướng đặc trưng học được từ dữ liệu lớn. Các hướng này không đồng đều về mức độ quan trọng, mà được sắp xếp theo thứ tự giảm dần của các giá trị kỳ dị. Cụ thể, năng lượng của ma trận được phân bố theo: $\| W \|_F^2 = \sum_{i=1}^{1024} \sigma_i^2$

Trong thực tế, ta có: $\sum_{i=1}^{1023} \sigma_i^2 \approx \| W \|_F^2$ điều này cho thấy 1023 thành phần đầu tiên đã chiếm gần như toàn bộ thông tin của phép biến đổi tuyến tính, trong khi thành phần cuối cùng chỉ đóng vai trò rất nhỏ.

Vậy tại sao model chỉ chọn phần dư hạng 1 để fine-tune?

Việc lựa chọn chỉ fine-tune một thành phần hạng 1 không phải là ngẫu nhiên, mà xuất phát từ các lý do toán học và hình học sau:

(1) Bảo toàn cấu trúc phổ của ma trận:

Nếu cập nhật toàn bộ W, các giá trị kỳ dị lớn có thể bị thay đổi, dẫn đến việc phá vỡ cấu trúc phổ ban đầu. Điều này tương đương với việc làm biến dạng các hướng chính trong không gian đặc trưng, gây ra hiện tượng lãng quên tri thức. Ngược lại, khi chỉ cập nhật thành phần nhỏ nhất: σ_{1024} ta đảm bảo rằng các thành phần chính $\sigma_1, \dots, \sigma_{1023}$ được giữ nguyên.

(2) Tách biệt không gian tri thức và không gian thích nghi:

Không gian đặc trưng có thể được phân tách thành hai không gian con trực giao:

$$\mathcal{H} = \mathcal{S}_{\text{semantic}} \oplus \mathcal{S}_{\text{artifact}}$$

$-$ $\mathcal{S}_{\text{semantic}}$: không gian chứa tri thức tiền huấn luyện (1023 chiều)

$-$ $\mathcal{S}_{\text{artifact}}$: không gian phần dư (1 chiều)

Nhờ tính trực giao: $\mathcal{S}_{\text{semantic}} \perp \mathcal{S}_{\text{artifact}}$ nên việc học trong không gian phần dư không làm ảnh hưởng đến không gian chính.

(3) Ràng buộc hạng thấp như một regularization mạnh

Điều kiện: $\text{rank}(\Delta W) = 1$ giới hạn mạnh khả năng biểu diễn của mô hình. Mọi cập nhật đều có dạng: $\Delta W = \alpha\, uv^T$ tức là chỉ thêm một hướng biến đổi duy nhất vào toàn bộ không gian 1024 chiều. Đây là một dạng regularization cực mạnh, giúp:

- giảm số tham số cần học
- hạn chế overfitting
- ổn định quá trình tối ưu

*(4) Trong quá trình thực nghiệm train với các **rank**(ΔW) thì với r = 1 thì phần dư hạng với hạng = 1 cho kết quả cao nhất.*

2.3.3. Cosine Classifier và Asymetric Contractive Loss

Sau khi đặc trưng ảnh được trích xuất từ backbone CLIP và được điều chỉnh cục bộ thông qua cơ chế SVD-PEFT, bài toán phân loại không còn được thực hiện bằng bộ phân loại tuyến tính truyền thống, mà thay vào đó sử dụng Cosine Classifier kết hợp với một chiến lược tối ưu hóa đặc biệt dựa trên Asymmetric Contrastive Loss.

(1) Cosine Classifier và biểu diễn trên mặt cầu siêu

Gọi $f(x) \in \mathbb{R}^{1024}$ là vector đặc trưng đầu ra từ backbone. Trước khi đưa vào bộ phân loại, vector này được chuẩn hóa:

$$\hat{f}(x) = \frac{f(x)}{\| f(x) \|_2}$$

Tương tự, các vector trọng số của bộ phân loại: $w_k \in \mathbb{R}^{1024}$ cũng được chuẩn hóa:

$$\widehat{w}_k = \frac{w_k}{\| w_k \|_2}$$

Khi đó, logit cho lớp k được tính bằng:

$$z_k = s \cdot \hat{f}(x)^T \widehat{w_k} = s \cdot \cos(\theta_k)$$

trong đó:

- $s = \exp$ (logit_scale) là hệ số tỉ lệ học được
- θ_k là góc giữa feature và weight

Hệ số s đóng vai trò điều chỉnh độ "sắc" của phân phối softmax. Khi s lớn, các giá trị logit được kéo giãn, giúp tăng độ phân tách giữa các lớp. Điều này đặc biệt quan trọng khi sử dụng cosine similarity, do giá trị bị giới hạn trong khoảng $[-1,1]$.

logit_scale là tham số được tối ưu trong quá trình huấn luyện, và thông qua phép biến đổi mũ, đảm bảo hệ số $s > 0$.

Hệ số s đóng vai trò tương đương với nghịch đảo của temperature trong các phương pháp học tương phản: $s = \frac{1}{\tau}$

Khi s lớn (tương đương τnhỏ), phân phối softmax trở nên "sắc" hơn, giúp tăng độ phân tách giữa các lớp. Điều này đặc biệt quan trọng trong cosine classifier, do giá trị cosine bị giới hạn trong khoảng $[-1,1]$.

Như vậy, quá trình phân loại không còn phụ thuộc vào độ lớn (magnitude), mà hoàn toàn dựa trên góc (angle) trong không gian đặc trưng.

Ý nghĩa hình học

Do các vector đã được chuẩn hóa: $\| \hat{f}(x) \|_2 = 1$ nên toàn bộ các điểm dữ liệu nằm trên mặt cầu đơn vị: $\mathbb{S}^{1023}$

Bài toán phân loại trở thành:

- kéo các điểm cùng lớp lại gần nhau trên mặt cầu
- đẩy các điểm khác lớp ra xa theo góc

Điều này đặc biệt phù hợp với đặc trưng của CLIP, vốn đã được huấn luyện theo hướng học metric (metric learning).

(2) Hạn chế của Cross-Entropy trong bài toán deepfake

Trong thiết lập phân loại nhị phân (real/fake), hàm mất mát Cross-Entropy được định nghĩa như sau:

$$\mathcal{L}_{CE} = -\log\left(\frac{e^{z_y}}{\sum_j e^{z_j}}\right)$$

trong đó $z_y$là logit tương ứng với nhãn đúng.

Hàm mất mát này có mục tiêu tối đa hóa xác suất dự đoán đúng, từ đó học một ranh giới quyết định giữa hai lớp. Tuy nhiên, Cross-Entropy chỉ quan tâm đến việc phân tách giữa các lớp mà không áp đặt ràng buộc hình học lên cấu trúc nội tại của không gian đặc trưng. Các mẫu thuộc cùng một lớp không bị ép phải co cụm trong không gian

embedding. Mô hình chỉ cần đảm bảo rằng: $z_y > z_{k \neq y}$ mà không cần tối ưu khoảng cách hoặc cấu trúc giữa các điểm dữ liệu.

Trong bài toán deepfake, điều này dẫn đến một hạn chế quan trọng:

- Lớp fake bao gồm nhiều phương pháp sinh khác nhau (Deepfakes, FaceSwap, Diffusion, ...), có phân bố rất đa dạng.
- Nếu sử dụng Cross-Entropy thuần túy, mô hình có xu hướng học một ranh giới phân tách đơn giản, nhưng không học được cấu trúc phân bố thực sự của các mẫu.

Hệ quả là:

- Không gian đặc trưng thiếu tính tổ chức (structure)
- Khả năng tổng quát hóa trên dữ liệu ngoài phân phối (out-of-distribution) bị suy giảm

(3) Asymmetric Contrastive Loss

Để khắc phục vấn đề này, mô hình sử dụng một biến thể của SupCon (mục 1.7), gọi là Asymmetric Contrastive Loss. Xét một batch gồm N mẫu với đặc trưng đã chuẩn hóa $\hat{f}_i$. Hàm mất mát được xây dựng chỉ trên các mẫu thuộc lớp **real**:

$$L_{\text{asym}} = -\frac{1}{|R^+|} \sum_{i \in R^+} \frac{1}{|P_{real}(i)|} \sum_{p \in P_{real}(i)} \log\left(\frac{\exp\left(\hat{f}_i^T \hat{f}_p / \tau\right)}{\sum_{a \neq i} \exp\left(\hat{f}_i^T \hat{f}_a / \tau\right)}\right)$$

trong đó:

- R^+: tập các mẫu real
- $P_{real}(i)$: tập các mẫu real khác cùng batch (positive samples)
- τ là hệ số nhiệt độ.

(4) Tính bất đối xứng (Asymmetry)

Khác với SupCon tiêu chuẩn Asymmetric Contrastive Loss chỉ kéo các mẫu real lại gần nhau, không ép các mẫu fake phải co cụm. Điều này tạo ra một cấu trúc hình học đặc biệt:

- Lớp real → tạo thành một cluster chặt
- Lớp fake → phân tán xung quanh, không bị ràng buộc

(5) Diễn giải hình học

Trong không gian mặt cầu:

- Các mẫu real bị "co lại": $\hat{f}_i \approx \hat{f}_j$ nếu $y_i = y_j = \text{real}$

- Các mẫu fake chỉ cần: $\hat{f}_{fake} \notin \text{cluster}_{real}$

⇒ Không gian quyết định trở thành: decision boundary = vùng bao quanh cluster real

(6) Các mối mối liên hệ

Ba thành phần SVD-PEFT, Cosine Classifier và Asymetric Contrastive Loss được thiết kế để phối hợp chặt chẽ các ưu tiên của biểu diễn và dữ liệu phân tách:

SVD-PEFT cố định định nghĩa các phần kỳ chính và chỉ cho phép cập nhật cập nhật trên phần dư hạng thấp, qua đó đảm bảo cấu trúc không có tiền huấn luyện cụ thể và hạn chế biến suy giảm chế độ.

Cosine Classifier chuẩn hóa vector đặc trưng lên mặt cầu đơn vị, chuyển bài toán phân loại sang không góc, giúp so sánh trở nên ổn định và phù hợp với cấu trúc đặc biệt được bảo vệ bởi SVD.

Asymetric Contrastive Loss bất chấp hoạt động trực tiếp trên không gian đã được chuẩn hóa, kéo dài các mẫu thực gần nhau và cho phép các phân tách mẫu giả, từ đó cấu hình tối ưu hóa cấu trúc phân tích.

SVD-PEFT ổn định không gian cụ thể, Cosine Classifier đưa dữ liệu lên mặt cầu và Mất tương phản bất đối xứng tái cấu trúc phân bố cấu trúc trên không gian đó, qua đó hình thành ranh giới quyết định rõ ràng và có khả năng hóa học tổng hợp cao

2.3.4. Hàm mất mát tổng thể

Hàm mất mát tổng thể của mô hình được xây dựng dưới dạng kết hợp tuyến tính giữa hàm mất mát phân loại và hàm mất mát cấu trúc hình học:

$$\mathcal{L} = \mathcal{L}_{CE} + \lambda \mathcal{L}_{\text{asym}}$$

- $\mathcal{L}_{CE}$ là hàm mất mát Cross-Entropy, đóng vai trò đảm bảo khả năng phân loại chính xác giữa hai lớp *real* và *fake*. Thành phần này tối ưu ranh giới quyết định (decision boundary) trong không gian đặc trưng, giúp mô hình học được ánh xạ từ đặc trưng sang nhãn một cách hiệu quả.
- $\mathcal{L}_{\text{asym}}$ là hàm mất mát Asymmetric Contrastive Loss, có nhiệm vụ tổ chức lại cấu trúc hình học của không gian embedding trên mặt cầu siêu. Cụ thể, hàm này kéo các mẫu thuộc lớp *real* lại gần nhau (tăng tính compactness), đồng thời không ép các mẫu *fake* phải co cụm, cho phép chúng phân bố tự do nhằm phản ánh tính đa dạng của các phương pháp giả mạo. Điều này giúp cải thiện đáng kể khả năng tổng quát hóa khi gặp dữ liệu ngoài phân phối.

- λ là hệ số cân bằng, điều chỉnh mức độ đóng góp của hai thành phần mất mát. Khi λlớn, mô hình ưu tiên học cấu trúc hình học của không gian đặc trưng; ngược lại, khi λnhỏ, mô hình tập trung nhiều hơn vào nhiệm vụ phân loại.

CHƯƠNG III: THIẾT LẬP THỰC NGHIỆM VÀ KẾT QUẢ ĐÁNH GIÁ

3.1. Thiết lập thực nghiệm và giao thức đánh giá

Để chứng minh tính hiệu quả của phương pháp phân rã SVD trong việc bảo toàn không gian đặc trưng và khả năng thích nghi của mô hình, chúng tôi thiết lập một quy trình đánh giá khắt khe dựa trên giao thức đánh giá chéo miền (cross-dataset evaluation).

- Dữ liệu huấn luyện: Mô hình chỉ được huấn luyện độc quyền trên tập dữ liệu chuẩn FaceForensics++ (FF++).
- Chiến lược đóng băng trọng số: Thành phần kỳ dị chính W_r được đóng băng hoàn toàn nhằm duy trì tri thức ngữ nghĩa từ mô hình tiền huấn luyện; quá trình tối ưu hóa chỉ diễn ra trên không gian con phần dư ΔW để học các dấu vết giả mạo đặc thù.
- Dữ liệu kiểm thử: Hệ thống được đánh giá trên 5 tập dữ liệu hoàn toàn xa lạ bao gồm: CDF-v2, DFD, DFDC, DFDCP và UADFV.
- Thách thức toán học: Sự khác biệt về phương pháp tạo sinh (từ 1 đến 8 kỹ thuật thao túng khác nhau) tạo ra hiện tượng xê dịch phân phối (domain shift), đòi hỏi ranh giới quyết định của mô hình phải có độ ổn định và tính tổng quát hóa cao.
- Độ đo hiệu suất: Sử dụng diện tích dưới đường cong ROC (AUC) ở cấp độ video làm thước đo chính.

3.2. Phân tích hiệu suất tổng quát hóa ngoại miền

Kết quả thực nghiệm tại Bảng 3.1 so sánh hiệu suất của mô hình cơ sở Effort (chỉ sử dụng SVD) và phiên bản cải tiến QHTD-CLIP (kết hợp SVD, hàm mất mát bất đối xứng và phân loại góc) với các phương pháp State-of-the-Art (SOTA).

Method	Param	CDF-v2	DFD	DFDC	DFDCP	UADFV	Avg
F3Net (2020)	22M	0.789	0.844	0.718	0.749	0.934	0.8068
SRM (2021)	55M	0.840	0.885	0.695	0.728	0.942	0.8180
RECCE (2022)	48M	0.823	0.891	0.696	0.734	0.944	0.8177
SLADD (2022a)	21M	0.837	0.904	0.772	0.756	-	0.8172
LSDA (2024a)	133M	0.875	0.881	0.701	0.812	-	0.8172
CDFA (2024)	87M	0.938	0.954	0.830	0.881	-	0.9007
Effort	**0.19M**	0.956	0.965	0.843	**0.909**	0.974	0.9294
QHTD-CLIP	**0.19M**	**0.957**	**0.985**	**0.862**	0.898	**0.994**	**0.9392**

Bảng 3.1: So sánh hiệu suất Video AUC (%) trên các tập dữ liệu ngoại miền

Nhận xét:

- Hiệu quả tham số: QHTD-CLIP đạt hiệu suất vượt trội trong khi chỉ sử dụng 0.19M tham số tinh chỉnh, thấp hơn hàng chục lần so với các phương pháp như CDFA hay SRM.
- Tính tổng quát hóa: Với AUC trung bình đạt 93.92%, mô hình chứng minh được khả năng tách biệt hiệu quả giữa không gian ngữ nghĩa và không gian giả mạo nhờ vào "mỏ neo" toán học SVD.

3.3. Phân tích hiệu suất nội miền

Để đánh giá khả năng nhận diện các kỹ thuật thao túng cụ thể, chúng tôi tiến hành kiểm thử mô hình trên các tập con của FaceForensics++ bao gồm: Deepfakes (DF), Face2Face (F2F), FaceSwap (FS) và NeuralTextures (NT).

Method	DF	F2F	FS	NT	Avg
ForAda	99.7	97	98.6	91.9	96.8
Efford	99.4	93.2	98.4	84.6	93.9
QHTD-CLIP	**99.9**	**99.5**	**99**	**97.8**	**99.05**

Bảng 3.2: Hiệu suất AUC (%) trên các kỹ thuật thao túng nội miền (FF++)

Phân tích kết quả:

- Mô hình QHTD-CLIP đạt kết quả gần như tuyệt đối trên kỹ thuật Deepfakes (99.9%) và Face2Face (99.5%).
- Sự cải thiện đáng kể ở kỹ thuật NT (từ 84.6% lên 97.8%) cho thấy việc kết hợp hàm mất mát tương phản bất đối xứng giúp mô hình nhạy bén hơn với các dấu vết tái tạo bề mặt tinh vi mà phương pháp SVD thuần túy có thể bỏ sót.

KẾT LUẬN

Trong nghiên cứu này, chúng tôi đã giải quyết một trong những rào cản lớn nhất của bài toán phát hiện ảnh giả mạo khuôn mặt (deepfake): sự suy biến không gian đặc trưng và hiện tượng lãng quên tri thức khi tái huấn luyện các mô hình nền tảng khổng lồ. Bằng cách tiếp cận vấn đề dưới lăng kính đại số tuyến tính và hình học không gian, tiểu luận đã làm rõ vai trò thiết yếu của các công cụ toán học trong việc điều hướng mạng nơ-ron.

Cốt lõi của giải pháp là việc ứng dụng Phân rã giá trị kỳ dị (SVD) để phân tách ma trận trọng số của khối Self-Attention thành hai không gian con trực giao tuyệt đối. Cơ chế này cho phép đóng băng các thành phần kỳ dị chính nhằm bảo tồn nguyên vẹn tri thức ngữ nghĩa gốc, đồng thời tạo ra một không gian phần dư (ΔW) độc lập để mô hình an tâm học hỏi các dấu vết giả mạo mà không làm xô lệch cấu trúc ban đầu.

Hơn thế nữa, kiến trúc QHTD-CLIP được đề xuất đã nâng cấp nền tảng SVD bằng việc tích hợp học metric trên mặt cầu siêu (Hyperspherical Metric Learning) thông qua hàm mất mát tương phản bất đối xứng. Sự kết hợp giữa mỏ neo toán học SVD (bảo vệ) và lực đẩy/hút hình học (khuếch đại) đã thiết lập một ranh giới quyết định vô cùng sắc nét. Kết quả thực nghiệm trên các kịch bản đánh giá chéo miền (cross-dataset) khắt khe nhất—bao gồm CDF-v2, DFD, DFDC, DFDCP và UADFV— đã chứng minh hiệu suất tổng quát hóa vượt trội của mô hình, đạt mức Video AUC trung bình lên tới 93.92% chỉ với 0.19M tham số được tinh chỉnh.

Tóm lại, nghiên cứu này không chỉ hệ thống hóa nền tảng toán học đằng sau các kỹ thuật Tinh chỉnh hiệu quả tham số (PEFT) mà còn mở ra một hướng đi mới: kiểm soát Trí tuệ Nhân tạo thông qua các ràng buộc hình học chặt chẽ. Trong tương lai, phương pháp phân rã trực giao này hoàn toàn có tiềm năng mở rộng sang các bài toán học tăng cường (incremental learning) hoặc phát hiện bất thường (anomaly detection) trong các miền dữ liệu phức tạp hơn.

TÀI LIỆU THAM KHẢO

[1] Z. Yan, J. Wang, P. Jin, K.-Y. Zhang, C. Liu, S. Chen, T. Yao, S. Ding, B. Wu, and L. Yuan, "Orthogonal subspace decomposition for generalizable AI-generated image detection," in Proceedings of the 42nd International Conference on Machine Learning (ICML), Vancouver, Canada, 2025.

[2] A. Yermakov, J. Cech, J. Matas, and M. Fritz, "Deepfake detection that generalizes across benchmarks," arXiv preprint arXiv:2508.06248, 2025.

[3] A. Radford, J. W. Kim, C. Hallacy, et al., "Learning transferable visual models from natural language supervision," in Proceedings of the International Conference on Machine Learning (ICML), 2021, pp. 8748-8763.

[4] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Nießner, "FaceForensics++: Learning to detect manipulated facial images," in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 1-11.

[5] E. B. Zaken, Y. Goldberg, and S. Ravfogel, "BitFit: Simple parameter-efficient fine-tuning for transformer-based masked language models," in Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL), 2022, pp. 1-9.

[6] W. Qi, Y.-P. Ruan, Y. Zuo, and T. Li, "Parameter-efficient tuning on layer normalization for pre-trained language models," arXiv preprint arXiv:2211.08682, 2022.

[7] U. Ojha, Y. Li, and Y. J. Lee, "Towards universal fake image detectors that generalize across generative models," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023, pp. 24480-24489.

[8] Y. Qian, G. Yin, L. Sheng, Z. Chen, and J. Shao, "Thinking in frequency: Face forgery detection by mining frequency-aware clues," in Proceedings of the European Conference on Computer Vision (ECCV), Springer, 2020, pp. 86-103.

[9] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, "Fine-tuning can distort pretrained features and underperform out-of-distribution," in International Conference on Learning Representations (ICLR), 2022.

[10] T. Wang and P. Isola, "Understanding contrastive representation learning through alignment and uniformity on the hypersphere," in Proceedings of the International Conference on Machine Learning (ICML), 2020.

[11] Z. Yan, Y. Zhang, X. Yuan, S. Lyu, and B. Wu, “DeepfakeBench: A comprehensive benchmark of deepfake detection,” in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS) Datasets Benchmarks Track, 2023.

[12] A. Radford et al., “Learning transferable visual models from natural language supervision,” in Int. Conf. Mach. Learn. (ICML), pp. 8748–8763, 2021.

[13] Xinjie Cui, Yuezun Li, Ao Luo, Jiaran Zhou, and Junyu Dong. Forensics adapter: Adapting CLIP for generaliz able face forgery detection. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 19207 19217, 2025.

[14] Z. Yan, J. Wang, Z. Wang, P. Jin, K.-Y. Zhang, S. Chen, T. Yao, S. Ding, B. Wu, and L. Yuan, "Effort: Efficient orthogonal modeling for generalizable AI-generated image detection," *arXiv preprint arXiv:2411.15633*, 2024.